

VERİ ANALİZİ • REMAKE

Keşifsel Veri Analizi

Sağlık göstergeleri veri setinin kalite, dağılım, ilişki ve alt grup analizleri

Yunus Emre Büyükgüler
21020513
İstatistik Bölümü

01 • KAPSAM

Veri setine hızlı bakış

Çalışma, 500 gözlem ve 25 değişkenden oluşan veri setini eksiksiz biçimde yeniden analiz eder. Eski rapordaki 450 satır bilgisi düzeltilmiş; tüm özetler doğrudan sağlanan CSV dosyasından hesaplanmıştır.



Şekil 1. Hedef değişkenlerin ve cinsiyetin örneklem içindeki dağılımı.

Temel bulgu: Diyabet sınıfı %33,0 oranındadır. KVH risk sınıfları dengesizdir; sınıf 2 yalnızca 94 gözlem içerir. Bu yapı, sonraki sınıflandırma çalışmalarında doğruluk yerine dengeli metrikleri gerekli kılar.

02 • DOĞRULAMA

Veri kalitesi ve tanımlayıcı istatistikler

CSV dosyasında eksik değer ve yinelenen kayıt yoktur. IQR yöntemi uç değerleri silmek için değil, dağılımın kuyruklarını görünür kılmak için kullanılmıştır; düşük sayıdaki uç gözlemler modelleme öncesi otomatik olarak kaldırılmamıştır.

Değişken	Ortalama	Std. sapma	Minimum	Medyan	Maksimum
Sistolik kan basıncı	120,29	15,03	90,00	120,34	157,76
Yaş	49,09	17,54	20,00	49,50	79,00
BKİ	24,98	4,08	15,00	24,99	38,43
Kan şekeri	99,73	19,18	60,00	99,79	149,07
HbA1c	5,47	0,96	4,00	5,37	8,70
Kolesterol	191,15	37,02	100,00	189,54	300,00
Trigliserid	149,00	49,22	50,00	147,47	318,59
CRP	5,19	2,81	0,10	5,08	13,94
D vitamini	25,15	9,38	10,00	25,04	57,85

Veri kalite kontrolü: aykırı değer görünümü




Şekil 2. IQR kuralına göre aykırı gözlem sayıları; çoğu değişkende yalnızca birkaç gözlem bulunmaktadır.

03 • TEK DEĞİŞKENLİ ANALİZ

Dağılımların görsel profili

Yaş örneklem boyunca geniş bir aralığa yayılırken; BKİ, kan şekeri ve kolesterol dağılımları merkeze yakın yoğunlaşmaktadır. Kesikli çizgiler medyanı gösterir. Histogramlar yalnızca merkezî eğilimi değil, olası çarpıklığı ve uç gözlemleri de birlikte sunar.

Temel klinik değişkenlerin dağılımları




Şekil 3. Altı temel klinik değişken için histogram ve çekirdek yoğunluk eğrileri.

Örneklem özeti: Ortalama yaş 49,09; ortalama BKİ 24,98; ortalama kan şekeri 99,73 ve ortalama HbA1c 5,47'dir. Bu değerler tanımlayıcıdır; klinik tanı veya nedensel çıkarım olarak yorumlanmamalıdır.

04 • KORELASYON

Değişkenler arasındaki ilişkiler

Pearson korelasyon matrisi doğrusal birliktelikleri özetler. Hedef değişkenlerle gözlenen korelasyonların çoğu zayıftır; bu durum veri setindeki sınıfların özellik uzayında belirgin biçimde ayrılmadığına işaret eder.




Şekil 4. Seçili sayısal değişkenlerin alt üçgen korelasyon matrisi.

Diyabet ile en yüksek mutlak doğrusal ilişki Hemoglobinin'de 0.082 düzeyindedir. Bu büyüklük tek başına güçlü bir ayırt edicilik sunmaz.

Diyabet gruplarının karşılaştırılması

Diyabet gruplarına göre değişken dağılımları




Şekil 5. Kutu grafikler gruplar arasındaki yoğun örtüşmeyi göstermektedir.

Değişken	Diyabet yok	Diyabet var
Yaş	49,51	48,24
BKİ	24,85	25,26
Kan şekeri	98,86	101,51
HbA1c	5,43	5,55
Kolesterol	191,96	189,52
Sistolik kan basıncı	120,86	119,14

Diyabet grubunda ortalama kan şekeri 101,51; diyabet olmayanlarda 98,86'dır. Fark görsel olarak sınırlıdır ve bu bölüm hipotez testi içermediğinden istatistiksel anlamlılık iddiası kurulmamıştır.

06 • ÖRÜNTÜ


Çok değişkenli görünüm



Şekil 6. Solda yaş-kan şekeri ilişkisi; sağda sekiz değişkenin iki boyutlu PCA izdüşümü.

Serpme diyagramında diyabet grupları geniş ölçüde örtüşmektedir. Benzer şekilde PCA düzleminde KVV risk sınıfları ayrı kümeler oluşturmamaktadır. PCA yalnızca görselleştirme amacıyla kullanılmış; sınıflandırma modellerinin yerine geçirilmemiştir.

Pandas ve NumPy ile veri manipülasyonu



Şekil 7. Boolean indeksleme ile seçilen alt grupların büyüklükleri.

07 • KAPANIŞ

Sonuç ve değerlendirme

199 Kolesterol > 200 %39,8	55 BKİ $\geq$ 30 %11,0	25 Diyabet & şeker > 120 %5,0	27 Üçlü filtre yaş > 50 dahil
----------------------------------	------------------------------	-------------------------------------	-------------------------------------

Kontrol edilmiş bulgular

- Veri seti teknik olarak temizdir: eksik değer ve yinelenen kayıt bulunmamaktadır.
- Diyabet ve KVH sınıfları için tek değişkenli ayırma zayıftır; sınıflandırmada yüksek başarı beklemek gerçekçi değildir.
- Eski rapordaki satır sayısı ve bazı özet istatistikler gerçek CSV ile uyuşmuyordu; tüm değerler yeniden hesaplandı.
- Boolean indekleme ve grup özetleri doğru sonuçlarla tekrarlandı; kan şekeri 150'nin üzerinde diyabetli gözlem bulunmadığı da doğrulandı.

Sınırlılık: Veri setinin üretim süreci ve klinik örnekleme yöntemi bilinmemektedir. Bulgular bu 500 gözlemle sınırlıdır; sağlık kararı veya kişisel risk değerlendirmesi amacıyla kullanılmamalıdır.

Yeniden üretilebilirlik: Tüm tablolar ve görseller `remake_ml_homeworks.py` dosyasıyla, sabit rastgelelik tohumu 42 kullanılarak üretildi.