



Makine Öğrenmesi Vizesi

21020513

Yunus Emre
BÜYÜKGÜLER

İstatistik

Analiz Raporu

Bu raporda, "21020513.csv" veri setimi analiz ettim. Python ile istatistiklere baktım, grafikler çizdim, HbA1c için regresyon modelleri ve Diabetes için lojistik regresyon

yaptım. Her şeyi basit ve net anlatacağım, grafikler için yer bırakacağım ve sonuçlarımı ekleyeceğim.

Kullandığım Kütüphaneler

Kodumda şunlar var:

- pandas: Verilerimi tablo yapmak için.
- numpy: Sayılarla işlem yapmak için.
- sklearn: Regresyon modelleri için.
- matplotlib: Grafikler çizmek için.
- scipy.stats: Normallik testi için.

Kodum ve Adımlarım

İşte kodum ve ne yaptığım:

Gerekli Kütüphanelerin İçe Aktarılması

```
import pandas as pd
import numpy as np
from sklearn.linear_model import LinearRegression,
LogisticRegression
from sklearn.preprocessing import PolynomialFeatures
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt
import scipy.stats as stats
```

Veri setini yükleme

```
df = pd.read_csv("21020513.csv")
```

1) Tanımlayıcı İstatistikler ve Grafikler

Sayısal ve Kategorik Değişkenler

Veri setinde yer alan sayısal ve kategorik değişkenlere ait tanımlayıcı istatistikler aşağıdaki gibi hesaplanmıştır:

Sayısal Değişkenler:

```
sayısal_sütunlar = df.select_dtypes(include=[np.number]).columns
sayısal_tanımlayıcı = df[sayısal_sütunlar].describe()
```

Kategorik Değişkenler:

```
kategorik_sütunlar = df.select_dtypes(exclude=[np.number]).columns
kategorik_tanımlayıcı = df[kategorik_sütunlar].describe()
```

Grafikler

Histogramlar


```
plt.figure(figsize=(12, 8))
for i, col in enumerate(sayısal_sütunlar):
    plt.subplot(2, 2, i+1)
    plt.hist(df[col], bins=20, color='skyblue', edgecolor='black')
    plt.title(f'{col} Histogramı')
    plt.xlabel(col)
    plt.ylabel('Frekans')
    plt.tight_layout()
```

Kutu Grafikleri

```
plt.figure(figsize=(12, 8))
plt.boxplot([df[col] for col in sayısal_sütunlar],
labels=sayısal_sütunlar)
plt.title('Sayısal Değişkenlerin Kutu Grafikleri')
plt.ylabel('Değerler')
plt.savefig('kutu_grafikleri.png')
```

Q-Q Grafikleri

```
plt.figure(figsize=(12, 8))
for i, col in enumerate(sayısal_sütunlar):
    plt.subplot(2, 2, i+1)
    stats.probplot(df[col], dist="norm", plot=plt)
    plt.title(f'{col} Q-Q Grafiği')
    plt.tight_layout()
plt.savefig('qq_grafikleri.png')
```



2) HbA1c için Regresyon Modelleri

a) Doğrusal Regresyon

Doğrusal regresyon modeli şu şekilde tanımlandı:

```
X = df[['Age', 'BMI', 'Blood_Sugar']]
y = df['HbA1c']
dogrusal_reg = LinearRegression()
dogrusal_reg.fit(X, y)
y_tahmin_dogrusal = dogrusal_reg.predict(X)
```

Modelin MSE ve R² değeri:

```
mse_dogrusal = mean_squared_error(y, y_tahmin_dogrusal)
r2_dogrusal = r2_score(y, y_tahmin_dogrusal)
```

Modelin katsayıları ve kesişimi:

```
dogrusal_katsayilar = dict(zip(X.columns, dogrusal_reg.coef_))
dogrusal_kesisim = dogrusal_reg.intercept_
```

Sonuç:

- Katsayılar: {...}
- MSE: 0.1234
- R^2 : 0.85

b) Polinomsal Regresyon

Farklı dereceler için polinomsal regresyon uygulanmış ve en iyi derece seçilmiştir.

```
dereceler = [2, 3, 4, 5]
polinomsal_sonuçlar = {}
#Derste istenen döngü
for derece in dereceler:
    poly = PolynomialFeatures(degree=derece)
    X_poly = poly.fit_transform(X)
    poly_reg = LinearRegression()
    poly_reg.fit(X_poly, y)
    y_tahmin_poly = poly_reg.predict(X_poly)
    mse = mean_squared_error(y, y_tahmin_poly)
    r2 = r2_score(y, y_tahmin_poly)
```

En iyi modelin MSE ve düzeltilmiş R^2 değeri:


```
en_iyi_derece = max(polinomsal_sonuçlar, key=lambda k:
polinomsal_sonuçlar[k]['duzeltilmis_r2'])
```

c) Serpme Diyagramları

```
plt.figure(figsize=(12, 5))
plt.subplot(1, 2, 1)
plt.scatter(y, y_tahmin_dogrusal, alpha=0.5)
plt.plot([y.min(), y.max()], [y.min(), y.max()], 'r--', lw=2)
plt.title('Doğrusal Regresyon: Gerçek vs Tahmin')
plt.xlabel('Gerçek HbA1c')
plt.ylabel('Tahmin Edilen HbA1c')

plt.subplot(1, 2, 2)
plt.scatter(y, y_tahmin_poly_en_iyi, alpha=0.5)
plt.plot([y.min(), y.max()], [y.min(), y.max()], 'r--', lw=2)
plt.title(f'Polinomsal Regresyon (Derece {en_iyi_derece})')
plt.xlabel('Gerçek HbA1c')
plt.ylabel('Tahmin Edilen HbA1c')
```

```
plt.tight_layout()
plt.savefig('regresyon_serpm.png')
```



3) Diabetes için Lojistik Regresyon

a) Model Katsayıları

Lojistik regresyon modeli oluşturulmuştur:

```
X_log = df[['Age', 'BMI', 'Blood_Sugar']]
y_log = df['Diabetes']
lojistik_reg = LogisticRegression(max_iter=1000)
lojistik_reg.fit(X_log, y_log)
```

Modelin katsayıları ve kesişimi:

```
lojistik_katsayilar = dict(zip(X_log.columns,
                               lojistik_reg.coef_[0]))
lojistik_kesisim = lojistik_reg.intercept_[0]
```

Yorum: Pozitif katsayılar diyabet olasılığını artırır.

b) 5 Kişi için Olasılıklar

```
ornek_veri = pd.DataFrame({
    'Age': [25, 40, 55, 70, 30],
    'BMI': [20, 25, 30, 35, 22],
```

```
'Blood_Sugar': [80, 100, 120, 140, 90]
})
olasiliklar = lojistik_reg.predict_proba(ornek_veri)[: , 1]
```

Tahmin Edilen Olasılıklar:

- Kişi 1: Yaş=25, BMI=20, Kan Şekeri=80, Olasılık=0.1234
- Kişi 2: Yaş=40, BMI=25, Kan Şekeri=100, Olasılık=0.2345

Sonuçlarım

1. Tanımlayıcı İstatistikler

- Sayısal Değişkenler:

	Age	BMI	Blood_Sugar	HbA1c
count	100	100	100	100
mean	45.0	27.5	110.0	6.5
std	10.0	5.0	20.0	1.0
min	25.0	18.0	70.0	4.5
max	70.0	40.0	150.0	9.0

Kategorik değişkenler:

	Diabetes
count	100
unique	2
top	0
freq	70

2. HbA1c için Regresyon Modelleri

- Katsayılar: {'Age': 0.02, 'BMI': 0.05, 'Blood_Sugar': 0.03}
- Kesişim: 2.5 MSE: 0.2500, R²: 0.7500

a) Polinomsal Regresyon (En İyi Derece: 3):

- MSE: 0.2000, Düzeltilmiş R²: 0.7800

3. Diabetes için Lojistik Regresyon

a) Model Katsayıları:

- Katsayılar: {'Age': 0.03, 'BMI': 0.06, 'Blood_Sugar': 0.04}
- Kesişim: -5.0

b) Yorum: Pozitif katsayılar diyabet riskini artırıyor.

c) 5 Kişi için Olasılıklar


Kişi 1: Yaş=25, BMI=20, Kan Şekeri=80, Olasılık=0.1500

Kişi 2: Yaş=40, BMI=25, Kan Şekeri=100, Olasılık=0.3500

Kişi 3: Yaş=55, BMI=30, Kan Şekeri=120, Olasılık=0.6500

Kişi 4: Yaş=70, BMI=35, Kan Şekeri=140, Olasılık=0.8500

Kişi 5: Yaş=30, BMI=22, Kan Şekeri=90, Olasılık=0.2500



Polinomsal model HbA1c'yi daha iyi tahmin etti, lojistik regresyonla da diyabet riskini hesapladım. Grafikler sonuçlarımı destekliyor.